独立测试：每点为一个训练种子的64批读出均值；黑点与误差线为种子均值及95%重抽样区间











